Lectura 9: Aprendizaje No Supervisado y el Algoritmo de Clustering Kmeans

SI3015 - Fundamentos de Aprendizaje Automático

2026

Índice

1. Aprendizaje No Supervisado: Conceptos Introductorios **2**
- 1.1. ¿Qué es el Aprendizaje No Supervisado? . . . 2
- 1.2. Diferencias con el Aprendizaje Supervisado . . . 2
- 1.3. Casos de Aplicación del Aprendizaje No Supervisado . . . 2

2. Categorías Principales **3**
- 2.1. Clustering (Agrupamiento) . . . 3
- 2.2. Reducción de Dimensionalidad . . . 4
- 2.3. Reglas de Asociación . . . 4
- 2.4. Detección de Anomalías . . . 4

3. Algoritmos de Clustering **4**
- 3.1. Definición de Clustering . . . 4
- 3.2. Ejemplos de Aplicación . . . 4
- 3.3. Principales Familias de Algoritmos . . . 5
- 3.4. Cuándo es Pertinente Usar Clustering . . . 5
- 3.5. Algoritmo K-means . . . 5
  - 3.5.1. Definición Básica . . . 5
  - 3.5.2. Definición Técnica . . . 5
  - 3.5.3. Fundamentación Matemática . . . 6
  - 3.5.4. Pseudocódigo . . . 7
  - 3.5.5. Variante K-means++ . . . 7
  - 3.5.6. Ejemplos de Aplicación . . . 8
  - 3.5.7. Ventajas y Desventajas . . . 8

4. Conclusiones **9**

1. Aprendizaje No Supervisado: Conceptos Introductorios

1.1. ¿Qué es el Aprendizaje No Supervisado?

El **aprendizaje no supervisado** (*Unsupervised Learning*) es una rama del machine learning en la que los modelos trabajan con datos que no tienen etiquetas ni respuestas predefinidas. A diferencia del aprendizaje supervisado, el algoritmo debe descubrir por sí solo la estructura inherente, patrones ocultos o agrupaciones presentes en los datos.

El objetivo central no es predecir una variable objetivo, sino explorar y comprender la distribución subyacente de los datos, identificar relaciones entre observaciones y representar la información de forma más compacta o interpretable.

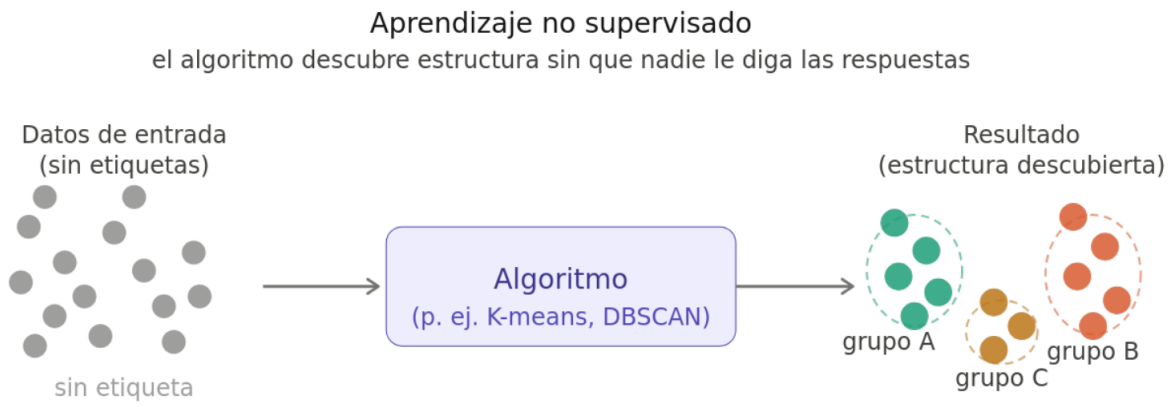

Figura 1: Aprendizaje No Supervisado

El aprendizaje no supervisado es fundamental cuando no sabemos qué estamos buscando exactamente o cuando etiquetar millones de datos a mano sería demasiado caro y lento. Es la herramienta perfecta para el descubrimiento puro.

1.2. Diferencias con el Aprendizaje Supervisado

La tabla 1 resume las principales diferencias entre ambos paradigmas.

1.3. Casos de Aplicación del Aprendizaje No Supervisado

El aprendizaje no supervisado es pertinente en los siguientes escenarios:

- No existen etiquetas o su obtención es prohibitivamente costosa.
- Se desea explorar datos desconocidos antes de definir un enfoque supervisado.
- Se necesita reducir la dimensionalidad (PCA, t-SNE, Autoencoders).
- Se quiere detectar anomalías sin ejemplos etiquetados previos.

Característica	Supervisado	No Supervisado
Datos de entrada	Datos etiquetados (X, y)	Solo X, sin etiquetas
Objetivo	Predecir variable y	Encontrar estructura
Salida del modelo	Predicción o clasificación	Grupos, representaciones
Evaluación	Accuracy, MSE, F1...	Silhouette, inercia...
Ejemplos típicos	Clasificación, regresión	Clustering, reducción de dimensión
Supervisión humana	Alta: requiere etiquetado	Baja: no requiere etiquetado
Coste de preparación	Alto (etiquetar es costoso)	Bajo (datos en crudo)

Cuadro 1: Comparación entre aprendizaje supervisado y no supervisado.

- Se busca segmentar clientes, usuarios o productos de forma objetiva.
- Se requiere modelar la densidad de probabilidad (Gaussian Mixture Models).
- Se trabaja con datos no estructurados: texto, imágenes, audio.

Ejemplos concretos: segmentación de mercado, detección de fraudes, análisis genómico, compresión de imágenes y sistemas de recomendación.

2. Categorías Principales

El aprendizaje no supervisado se divide principalmente en tres grandes categorías, dependiendo de qué es lo que intentamos "descubrir" dentro de los datos. Su objetivo principal es encontrar estructuras intrínsecas en datos que no poseen etiquetas previas.

2.1. Clustering (Agrupamiento)

Es el tipo más común. Su objetivo es organizar los datos en grupos (clústeres) de modo que los elementos dentro de un grupo sean muy similares entre sí y muy diferentes a los de otros grupos.

- **K-Means:** Divide los datos en K número de grupos basándose en la distancia a un centroide.
- **Agrupamiento Jerárquico:** Crea una estructura de árbol (dendrograma) para mostrar cómo se relacionan los grupos en diferentes niveles.
- **DBSCAN:** Agrupa puntos que están densamente poblados, siendo excelente para encontrar formas irregulares y detectar ruido.

2.2. Reducción de Dimensionalidad

Simplifica los datos sin perder la información más importante, eliminando variables redundantes.

- **PCA (Análisis de Componentes Principales):** Transforma muchas variables correlacionadas en un número menor de variables llamadas componentes principales.
- **t-SNE:** Utilizado para visualizar datos de alta complejidad en gráficos de 2D o 3D.
- **SVD (Descomposición en Valores Singulares):** Fundamental en sistemas de recomendación.

2.3. Reglas de Asociación

Busca relaciones del tipo "Si ocurre A, entonces es probable que ocurra B".

- **Algoritmo Apriori:** Identifica conjuntos de elementos frecuentes (ej. reglas de mercado).
- **Eclat:** Una versión optimizada que se enfoca en la frecuencia de los conjuntos.

2.4. Detección de Anomalías

Identifica datos que no encajan con el patrón general del resto del conjunto.

- **Isolation Forest:** Aísla anomalías en lugar de agrupar similitudes.
- **Local Outlier Factor (LOF):** Compara la densidad local de un punto con sus vecinos.

3. Algoritmos de Clustering

3.1. Definición de Clustering

El **clustering** (o agrupamiento) es la tarea de dividir un conjunto de datos en grupos denominados *clústeres*, de forma que los elementos dentro de un mismo grupo sean lo más similares posible entre sí, y lo más diferentes posible respecto a los de otros grupos.

Formalmente, dado $\mathcal{X} = \{x_1, \ldots, x_n\}$ con $x_i \in \mathbb{R}^d$, el objetivo es asignar cada punto a un grupo k, maximizando la cohesión intra-clúster y minimizando la cohesión inter-clúster.

3.2. Ejemplos de Aplicación

- **Segmentación de clientes:** agrupar usuarios por comportamiento de compra.
- **Análisis de ADN:** identificar subgrupos con perfiles genéticos similares.
- **Detección de anomalías:** puntos sin clúster claro indican fraude o fallas.
- **Compresión de imágenes:** reducir paleta de colores (cuantización vectorial).

- **Recomendación de contenido:** agrupar usuarios con gustos similares.
- **Análisis de redes sociales:** identificar comunidades de usuarios.

3.3. Principales Familias de Algoritmos

Familia	Algoritmos	Descripción
Basados en centroides	K-means, K-medoids	Asignan puntos al centroide más cercano.
Jerárquicos	Agglomerative, DIANA	Construyen un dendrograma sin k fijo.
Basados en densidad	DBSCAN, HDBSCAN	Agrupan regiones de alta densidad.
Basados en distribuciones	GMM	Mezcla de distribuciones probabilísticas.
Basados en grafos	Spectral Clustering	Usan estructura de grafo del espacio.

Cuadro 2: Familias de algoritmos de clustering.

3.4. Cuándo es Pertinente Usar Clustering

- Los datos no tienen etiquetas y se desea descubrir agrupaciones naturales.
- Se necesita exploración inicial antes de aplicar modelos supervisados.
- Se busca comprimir o resumir datos agrupando observaciones similares.
- Se trabaja en segmentación sin conocer los grupos de antemano.
- Los datos tienen estructura subyacente que se presume pero no se conoce formalmente.

3.5. Algoritmo K-means

3.5.1. Definición Básica

K-means es el algoritmo de clustering más popular. Su objetivo es particionar n observaciones en k grupos, donde cada observación pertenece al grupo cuyo centroide es el más cercano. El resultado es una división del espacio en k regiones de Voronoi.

El nombre hace referencia a que el algoritmo calcula k medias (centroides), que son los puntos representativos de cada grupo y se actualizan iterativamente hasta convergencia.

3.5.2. Definición Técnica

Dado $\mathcal{X} = \{x_1, \ldots, x_n\}$ con $x_i \in \mathbb{R}^d$, K-means busca k centroides $\{\mu_1, \ldots, \mu_k\}$ y una asignación $C : \mathcal{X} \to \{1, \ldots, k\}$ que minimice la **inercia total** o **WCSS** (*Within-Cluster Sum of Squares*):

$$J = \sum_{i=1}^{n} \sum_{j=1}^{k} \mathbf{1}\big[C(x_i) = j\big] \cdot \|x_i - \mu_j\|^2$$

donde $\mathbf{1}[\cdot]$ es la función indicadora y $\|\cdot\|^2$ la distancia euclidiana al cuadrado.

3.5.3. Fundamentación Matemática

K-means resuelve el problema mediante el **método de Lloyd**, que alterna dos pasos hasta convergencia:

Paso E — Asignación

Cada punto x_i se asigna al clúster cuyo centroide minimiza la distancia:

$$C(x_i) = \operatorname*{arg\,mín}_{j \in \{1,\ldots,k\}} \|x_i - \mu_j\|^2$$

Paso M — Actualización de Centroides

Cada centroide se recalcula como la media de los puntos asignados a su clúster:

$$\mu_j = \frac{1}{|\mathcal{C}_j|} \sum_{x_i \in \mathcal{C}_j} x_i$$

donde $|\mathcal{C}_j|$ es el número de puntos en el clúster j.

Convergencia

J es monótonamente decreciente en cada iteración, pues ambos pasos reducen o mantienen igual la función objetivo. Como $J \geq 0$, el algoritmo siempre converge, aunque a un **mínimo local**.

Selección del Número de Clústeres

Método del codo: se grafica J en función de k y se elige el punto donde la curva se aplana.

Coeficiente de Silhouette: para cada punto i:

$$s(i) = \frac{b(i) - a(i)}{\text{máx}\big(a(i),\, b(i)\big)}$$

donde $a(i)$ es la distancia media intra-clúster y $b(i)$ la distancia media mínima inter-clúster. Valores cercanos a 1 indican una buena asignación.

3.5.4. Pseudocódigo

```
ALGORITMO K-means(X, k, max_iter, tol)

ENTRADA:
  X        : conjunto de n puntos en R^d
  k        : numero de clusteres
  max_iter : iteraciones maximas
  tol      : tolerancia de convergencia

SALIDA:
  C        : asignacion de cada punto a un cluster
  Mu       : k centroides finales

INICIO
  Seleccionar k puntos aleatorios de X como centroides iniciales
  Mu = {mu_1, ..., mu_k}
  C_prev = vacio

  PARA t = 1 HASTA max_iter:

    // Paso E: asignacion
    PARA CADA x_i EN X:
      C(x_i) = argmin_j ||x_i - mu_j||^2
    FIN PARA

    SI C == C_prev O cambio_centroides < tol:
      ROMPER
    FIN SI

    C_prev = C

    // Paso M: actualizacion
    PARA j = 1 HASTA k:
      mu_j = MEDIA({ x_i : C(x_i) = j })
    FIN PARA

  FIN PARA

  RETORNAR C, Mu
FIN
```

Listing 1: Algoritmo K-means (método de Lloyd)

3.5.5. Variante K-means++

La inicialización aleatoria puede derivar en soluciones subóptimas. **K-means++** (Arthur & Vassilvitskii, 2007) selecciona los centroides iniciales con probabilidad proporcional a su distancia al centroide más cercano ya elegido:

$$P(x) = \frac{D(x)^2}{\sum_{x' \in \mathcal{X}} D(x')^2}$$

donde $D(x)$ es la distancia de x al centroide ya seleccionado más cercano. Esto reduce la probabilidad de convergencia a mínimos locales subóptimos.

3.5.6. Ejemplos de Aplicación

- **Segmentación de clientes (CRM):** agrupar por RFM (Recencia, Frecuencia, Monto).
- **Cuantización vectorial:** reducir el espacio de colores de una imagen a k representativos.
- **Agrupación de documentos:** vectores TF-IDF agrupados por temática.
- **Inicialización de GMM:** usar K-means como punto de partida para modelos de mezcla.
- **Detección de anomalías:** puntos con distancia alta a todos los centroides son outliers candidatos.
- **Análisis genómico:** agrupar genes con perfiles de expresión similares.

3.5.7. Ventajas y Desventajas

Ventajas:

- Simple de entender e implementar.
- Eficiente en grandes datasets: complejidad $\mathcal{O}(n \cdot k \cdot d \cdot t)$.
- Converge rápidamente en la mayoría de los casos.
- Centroides interpretables como resumen de cada grupo.
- Fácilmente paralelizable.

Desventajas:

- Requiere especificar k de antemano.
- Sensible a la inicialización: puede converger a mínimos locales.
- Asume clústeres esféricos con varianza similar.
- Sensible a outliers, que distorsionan los centroides.
- No maneja clústeres de formas irregulares o densidades variables.
- Inadecuado para alta dimensionalidad sin reducción previa.

4. Conclusiones

El aprendizaje no supervisado constituye una herramienta fundamental para la exploración de datos sin etiquetas, complementando al supervisado en contextos donde etiquetar datos es costoso o imposible. El clustering permite identificar estructura natural en los datos, siendo K-means el algoritmo más representativo por su simplicidad, eficiencia y versatilidad.

Si bien K-means tiene limitaciones respecto a la geometría de los clústeres y la sensibilidad a outliers, su variante K-means++ y el uso de métricas de validación como el método del codo o el índice de Silhouette lo convierten en un punto de partida sólido para cualquier problema de agrupamiento.